AI Gateways

Mais segurança e maior governança em suas soluções de Inteligência Artificial!

Carlos Machel & Carlos Nogueira



PALESTRANTE

Carlos Machel

- Microsoft MVP (Most Valuable Professional)
- +10 anos em desenvolvimento de software
- Lead Software Developer na Azure Brasil
- Lives e vídeos no YouTube da Azure Brasil
- Criador da série “MAF na prática”

Conecte-se comigo

Aponte a câmera para o QR code



PALESTRANTE

Carlos Nogueira

- Arquiteto de Soluções
- Especialista em API e IA Gateway & ESB
- Ciência da Computação - UERJ
- DevOps, Cloud e IA - PUC
- 13 anos de experiência na área de Tecnologia

Conecte-se comigo

Aponte a câmera para o QR code



Agenda

01 O que é um AI Gateway e por que usar

02 Segurança e governança

03 Riscos de IA segundo a OWASP

04 Alternativas e arquitetura de referência

05 Demo: APISIX na prática

06 Aprendizados e perguntas

O que é um AI Gateway?

Um ponto único entre suas aplicações e os modelos de IA, onde as políticas são aplicadas.



Por que utilizar um AI Gateway?

Governança

Políticas centralizadas para todo uso de IA

Segurança

Controle de acesso, guardrails e credenciais fora das aplicações

Observabilidade

Métricas, logs e rastreamento de cada chamada

Custos

Controle e acompanhamento do consumo de tokens

Flexibilidade

Troca de modelos sem alterar aplicações e payloads padronizados

AI Gateways x Segurança

- Autenticação e autorização centralizadas
- Controle de acesso por aplicação ou usuário
- Rate limiting e proteção contra abusos
- Gerenciamento seguro de credenciais
- Filtros e guardrails para requisições e respostas

Governança e Controle com AI Gateways



Políticas de uso dos modelos



Limites de tokens e requisições



Controle de modelos e provedores permitidos



Auditoria e rastreabilidade das chamadas



Acompanhamento de custos (FinOps)

Tudo em um só lugar, sem mudar o código das aplicações.

Iniciativas OWASP voltadas à área de IA

LLM

OWASP Top 10 for LLM Applications 2026

Onde o gateway ajuda

- ✓ Guardrails contra prompt injection
- ✓ Filtros de dados sensíveis (PII)
- ✓ Limite de tokens contra consumo sem controle

AGENTES

OWASP Top 10 for Agentic Applications for 2026

Onde o gateway ajuda

- ✓ Identidade e credenciais por agente
- ✓ Limites de chamadas e tokens por agente
- ✓ Auditoria das ações executadas

MCP

OWASP MCP Top 10

Onde o gateway ajuda

- ✓ Tokens e segredos fora dos clientes
- ✓ Autenticação e allowlist de servidores MCP
- ✓ Logs centralizados das chamadas

AI Gateways: algumas alternativas



APISIX



Azure API Management



Azure AI Gateway



Kong

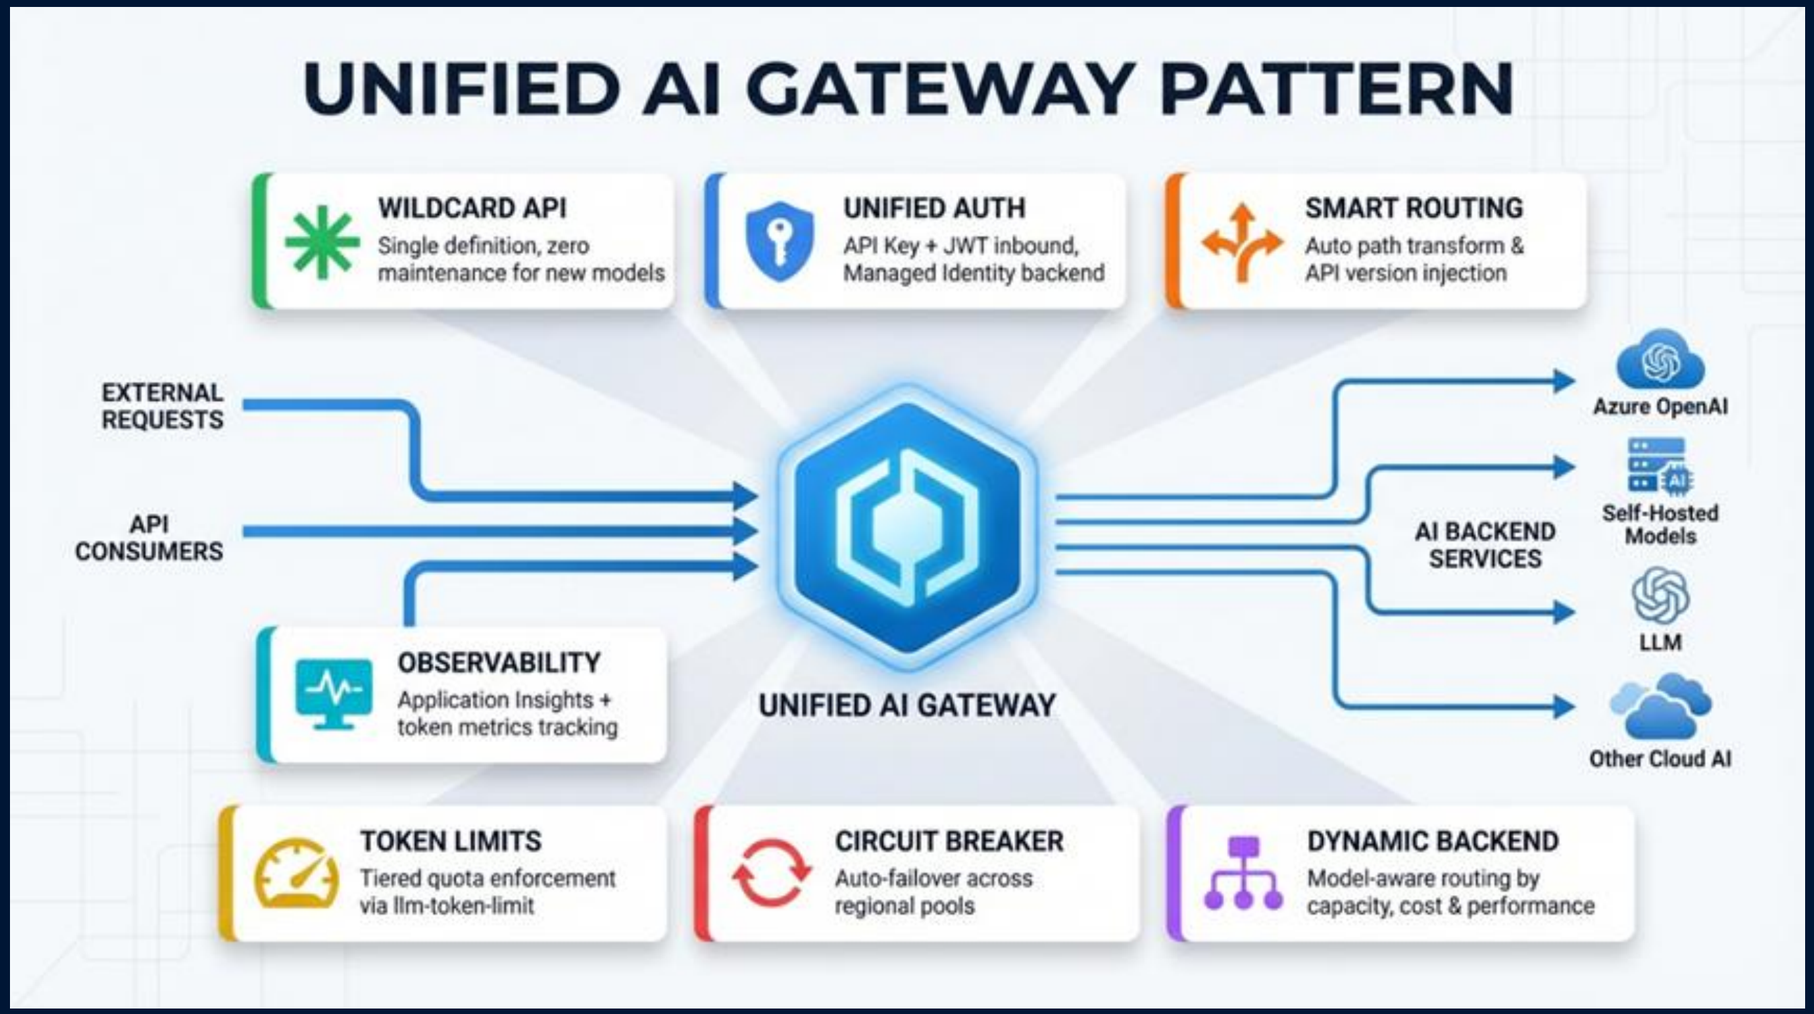


LiteLLM

e outros...

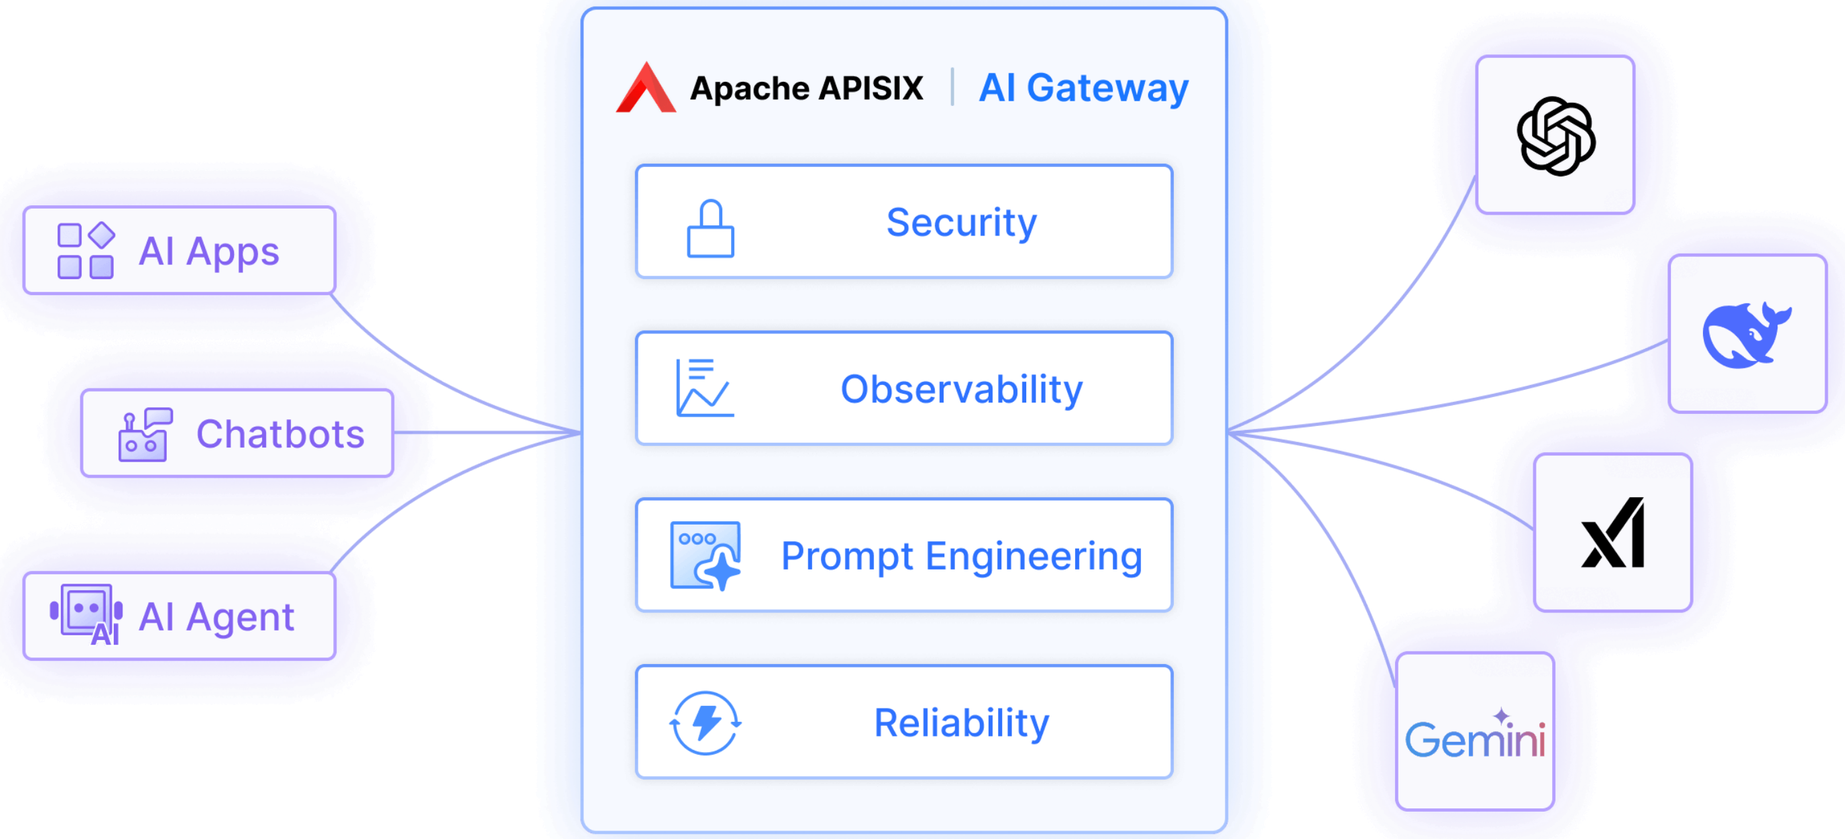
Escolha pelo seu stack e requisitos

Padrão de AI Gateway unificado



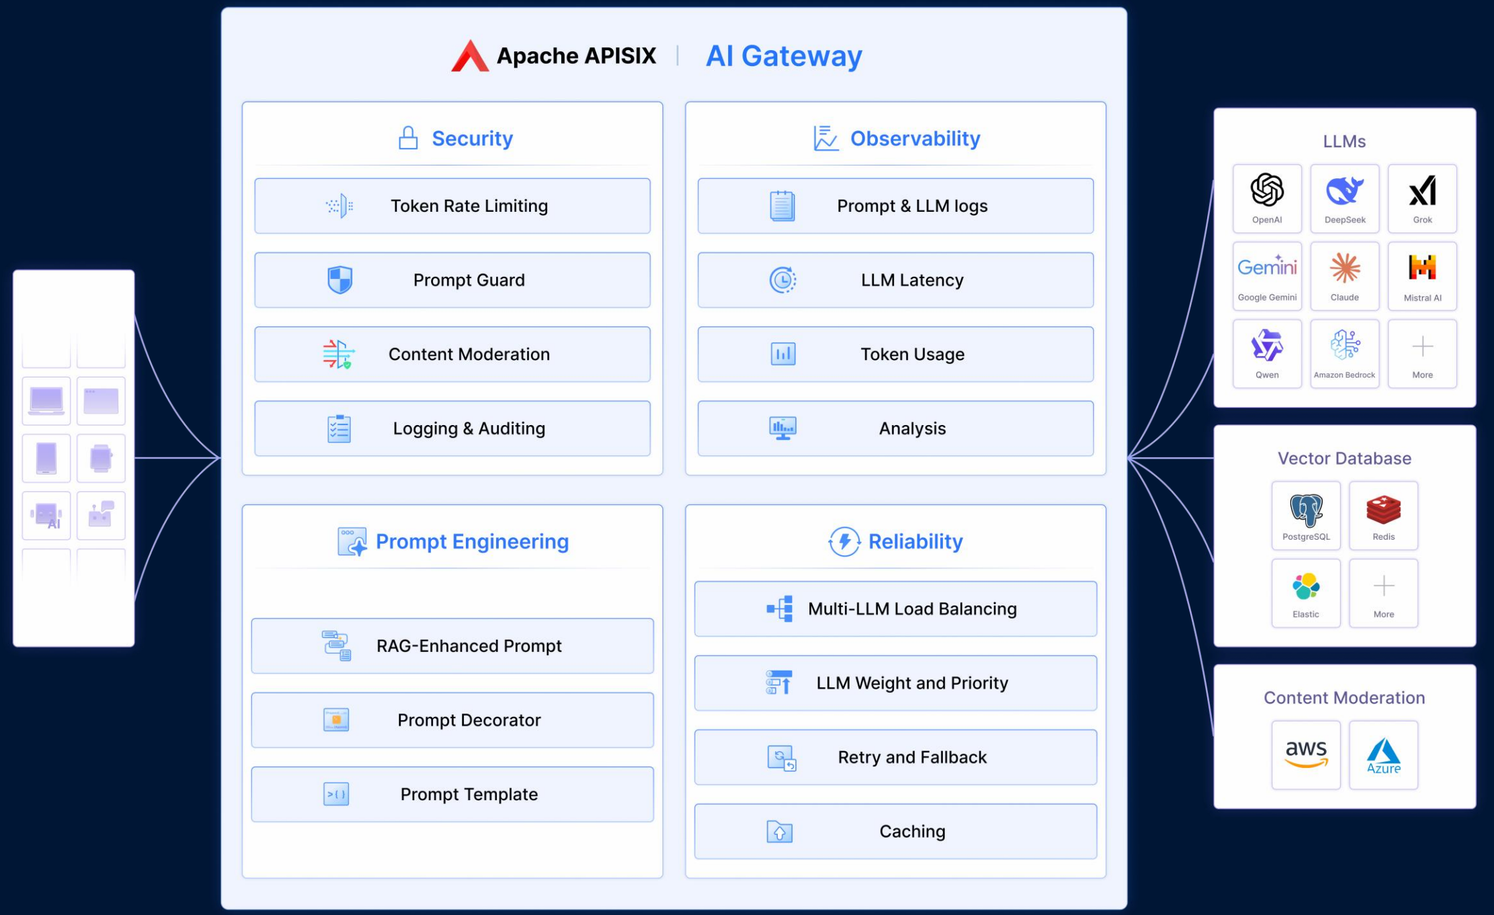
- **Fonte: Microsoft**

APISIX AI Gateway: visão geral



- **Fonte: APISIX**

APISIX AI Gateway: arquitetura



- **Fonte: APISIX**

Roteiro da demo

Apache APISIX na frente de um modelo no Azure



Rota de IA

`ai-proxy`

A aplicação chama o gateway; a chave do modelo fica só nele

Autenticação

`key-auth`

Um consumidor por aplicação. Sem chave: 401

Limite de tokens

`ai-rate-limiting`

Cota de tokens por consumidor. Estourou: 429

Guardrail

`ai-prompt-guard`

Bloqueia padrões de prompt injection

Multi-provedor

`ai-proxy-multi`

Fallback entre provedores e métricas de uso

O que levar desta palestra

01

Trate o acesso a modelos como infraestrutura: um ponto único, com políticas.

02

Segurança, custos e observabilidade se resolvem no gateway, sem reescrever aplicações.

03

Comece pequeno: rota + autenticação + limite de tokens já trazem ganho imediato.

Obrigada(o)!



Carlos Machel



Carlos Nogueira